Stochastik und Statistik

Jil Zerndt, Lucien Perret December 2024

ntro

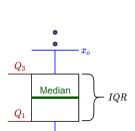
Begriffe

Grundlegende Begriffe

- $\Omega = Grundgesamtheit$
- n = Anzahl Objekte
- X = Stichprobenwerte
- a = Ausprägungen
- h = Absolute Häufigkeit
- f = Relative Häufigkeit
- H = Kumulative Absolute Häufigkeit
- F = Kumulative Relative Häufigkeit

Boxplot

- $Q_1, Q_2 = x_{\text{med}}, Q_3$
- $IQR = Q_3 Q_1$
- Untere Antenne x_u : $u = \min [Q_1 - 1.5 \cdot IQR, Q_1]$
- Obere Antenne x_0 : $o = \max [Q_3 + 1.5 \cdot IQR, Q_3]$
- Ausreisser: $x_i < x_u \lor x_i > x_0$



Deskriptive Statistik

Bivariate Daten (Merkmale)

- 2x kategoriell → Kontingenztabelle + Mosaikplot
- $1x \text{ kategoriell} + 1x \text{ metrisch} \rightarrow \text{Boxplot oder Stripchart}$
- $2x \text{ metrisch} \rightarrow \text{Streudiagramm}$

Absolute Häufigkeiten

$$H = \sum_{i=1}^{n} h_i$$

H: Absolute Häufigkeit,h_i: Einzelhäufigkeit der i-ten

Beobachtung,

n: Anzahl der Beobachtungen.

Relative Häufigkeiten

$$F = \sum_{i=1}^{m} f_i, \quad F(x) = \frac{H(x)}{n}$$

F: Relative Häufigkeit,

f_i: Einzelrelative Häufigkeit der i-ten Beobachtung,

H(x): Absolute Häufigkeit eines Wertes x,

 $n{:}$ Anzahl der Beobachtungen.

| Kennwerte (Lagemasse) -

Quantil

$$i = \lceil n \cdot q \rceil, \quad Q = x_i = x_{\lceil n \cdot q \rceil}$$

- i: Position des Quantils,
- n: Anzahl der Beobachtungen.
- q: Quantilswert (z. B. 0.25 für das erste Quartil),
- x_i : Beobachtung an Position i.

Interquartilsabstand

$IQR = Q_3 - Q_1$

IQR: Interquartilsabstand,

 Q_3 : Oberes Quartil (75. Perzentil),

 Q_1 : Unteres Quartil (25. Perzen-

til).

Modus

 $x_{\text{mod}} = \text{H\"{a}ufigste Wert}$

Arithmetisches Mittel

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i = \sum_{i=1}^{m} a_i \cdot f_i$$

- \bar{x} : Arithmetisches Mittel,
- $n{:}$ Anzahl der Beobachtungen,
- x_i : Einzelbeobachtung,
- a_i : Klassenmitte,
- f_i: Relative Häufigkeit der Klas-

Median

$$\left\{ \begin{array}{c} x_{\left\lceil\frac{n+1}{2}\right\rceil} & n \text{ ungerade} \\ \\ 0.5 \cdot \left(x_{\left\lceil\frac{n}{2}\right\rceil} + x_{\left\lceil\frac{n}{2}+1\right\rceil}\right) & n \text{ gerade} \end{array} \right.$$

n: Anzahl der Beobachtungen,

 $x_{[k]}$: Beobachtung an der k-ten Position.

Stichprobenvarianz s^2 (Streumasse)

$$s^{2} = \frac{1}{n} \sum_{i=1}^{n} (x_{i} - \bar{x})^{2} = \overline{x^{2}} - \bar{x}^{2}, \quad (s_{kor})^{2} = \frac{1}{n-1} \sum_{i=1}^{n} (x_{i} - \bar{x})^{2}$$
$$(s_{kor})^{2} = \frac{n}{n-1} \cdot s^{2}$$

 s^2 : Stichprobenvarianz,

 $s_{\rm kor}^2$: Korrigierte Stichprobenvarianz,

 x_i : Einzelbeobachtung,

 \bar{x} : Arithmetisches Mittel.

n: Anzahl der Beobachtungen.

Standardabweichung s (Streumasse)

$$s = \sqrt{\frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})^2} = \sqrt{\overline{x^2} - \bar{x}^2}, \quad s_{\text{kor}} = \sqrt{\frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2}$$

s: Standardabweichung,

skor: Korrigierte Standardabweichung,

 x_i : Einzelbeobachtung,

 \bar{x} : Arithmetisches Mittel,

n: Anzahl der Beobachtungen.

PDF + CDF -

Nicht klassierte Daten (PMF und CDF)

Die absolute Häufigkeit kann als Funktion $h:\mathbb{R}\to\mathbb{R}$ bezeichnet werden.

$$h_i$$

 h_i : Absolute Häufigkeit der i-ten Beobachtung.

Die relative Häufigkeit kann als Funktion $f:\mathbb{R}\to\mathbb{R}$ bezeichnet werden.

$$f_i = \frac{h_i}{n}$$

 f_i : Relative Häufigkeit der i-ten Beobachtung,

 h_i : Absolute Häufigkeit der *i*-ten Beobachtung,

n: Anzahl der Beobachtungen.

PMF und CDF für diskrete und stetige Daten -

Diskrete Verteilungsfunktionen

Die absolute Häufigkeit kann als Funktion $h:\mathbb{R}\to\mathbb{R}$ bezeichnet werden:

$$h_{i}$$

Die relative Häufigkeit kann als Funktion $f:\mathbb{R} \to \mathbb{R}$ bezeichnet werden:

$$f_i = \frac{h_i}{n}$$

Diskrete Häufigkeitsverteilung

a_i	397	398	399	400	Total
h_i	1	3	7	5	16
f_i	$\frac{1}{16}$	3 16	$\frac{7}{16}$	$\frac{5}{16}$	1
H_i	1	4	11	16	
F_i	$\frac{1}{16}$	$\frac{4}{16}$	$\frac{11}{16}$	$\frac{16}{16}$	

Klassenbildung (Faustregeln)

- Die Klassen sollten gleich breit gewählt werden
- Die Anzahl der Klassen sollte zwischen 5 und 20 liegen, jedoch \sqrt{n} nicht überschreiben.

Stetige Verteilungsfunktionen

Die absolute Häufigkeitsdichtefunktion erhält man, indem der Wert der absoluten Häufigkeit h_i durch die Klassenbreite (Säulenbreite) d_i geteilt wird:

$$h(x) = \frac{h_i}{d_i}$$

Die relative Häufigkeitsdichtefunktion (PDF) $f: \mathbb{R} \to [0,1]$ erhält man aus der absoluten Häufigkeitsdichtefunktion, indem man den Wert durch die Stichprobengrösse n teilt:

$$PDF = f(x) = \frac{h(x)}{n}$$

Stetige Häufigkeitsverteilung

	Klassen	100-200	200-500	500-800	800-1000	Total
	h_i	35	182	317	84	618
	f_i	35 618	182 618	317 618	84 618	Area = 1
	d_i	100	300	300	200	
	h(x)	$\frac{35}{100}$	$\frac{182}{300}$	$\frac{317}{300}$	$\frac{84}{200}$	
ĺ	f(x)	$\frac{35}{100.618}$	182 300·618	317 300·618	$\frac{84}{200.618}$	

Varianz und Kovarianz

Varianz s_x^2, s_y^2 :

$$(s_x)^2 = \overline{x^2} - \bar{x}^2, \quad (s_y)^2 = \overline{y^2} - \bar{y}^2$$

Kovarianz s_{xy} :

$$s_{xy} = \frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}), \quad s_{xy} = \overline{xy} - \bar{x} \cdot \bar{y}$$

Abkürzungen

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^{n} y_i$$

$$\overline{xy} = \frac{1}{n} \sum_{i=1}^{n} x_i \cdot y_i$$

Rang-Varianz und Kovarianz

Varianz (Ränge) $(s_{rg(x)})^2, (s_{rg(y)})^2$:

$$(s_{rg(x)})^2 = \overline{rg(x)^2} - (\overline{rg(x)})^2, \quad (s_{rg(y)})^2 = \overline{rg(y)^2} - (\overline{rg(y)})^2$$

Kovarianz (Ränge) $s_{rq(xy)}$:

$$s_{rg(xy)} = \overline{rg(xy)} - \overline{rg(x)} \cdot \overline{rg(y)} = \overline{rg(xy)} - \frac{(n+1)^2}{4}$$

Der Korrelationskoeffizient (Pearson) r_{xy}

$$r_{xy} = \frac{s_{xy}}{s_x \cdot s_y} = \frac{\overline{xy} - \overline{x} \cdot \overline{y}}{\sqrt{\overline{x^2} - \overline{x}^2} \cdot \sqrt{\overline{y^2} - \overline{y}^2}}$$

Ist der Korrelationskoeffizient r_{xy} :

- $r_{xy} \approx 1 \rightarrow \text{starker positiver linearer Zusammenhang}$
- $r_{xy} \approx -1 \rightarrow \text{starker negativer linearer Zusammenhang}$
- $r_{xy} \approx 0 \rightarrow \text{keine lineare Korrelation}$

Bemerkungen

Auch wenn zwischen zwei Grössen eine Korrelation besteht, so muss das noch lange nicht einen kausalen Zusammenhang bedeuten. Man spricht von Scheinkorrelation.

Graphische Darstellung

• Form linear / gekrümmt

• Richtung positiver / negativer Zusammenhang

• Stärke starke / schwache Streuung

Korrelationskoeffizient (Spearman) r_{sp}

$$r_{sp} = \frac{s_{rg(xy)}}{s_{rg(x)} \cdot s_{rg(y)}} = \frac{\overline{rg(xy)} - \overline{rg(x)} \cdot \overline{rg(y)}}{\sqrt{\overline{rg(x)^2} - (\overline{rg(x)})^2} \cdot \sqrt{\overline{rg(y)^2} - (\overline{rg(y)})^2}}$$

Vereinfachte Formel, sofern alle Ränge unterschiedlich sind:

$$r_{sp} = 1 - \frac{6 \cdot \sum_{i=1}^{n} d_i^2}{n \cdot (n^2 - 1)}, \text{ mit } d_i = rg(x_i) - rg(y_i)$$

Ränge

Der Rang $rg(x_i)$ des Stichprobenwertes x_i ist definiert als der Index von x_i in der nach der Grösse geordneten Stichprobe.

i	1	2	3	4	5	6
x_i	23	27	35	35	42	59
$rg(x_i)$	1	2	3.5	3.5	5	6

Kombinatorik

Fakultät

$$n! = 1 \cdot 2 \cdot \ldots \cdot n = \prod_{k=1}^{n} k$$

n= Die positive ganze Zahl, für die die Fakultät berechnet wird k= Laufvariable in der Produktnotation

 \prod = Produkt aller Terme von k = 1 bis n

Binomialkoeffizient

Wie viele Möglichkeiten gibt es k Objekte aus einer Gesamtheit von n Objekten auszuwählen.

$$\binom{n}{k} = \frac{n!}{(n-k)! \cdot k!}$$

n = Gesamtanzahl der Objekte in der Menge

k = Anzahl der auszuwählenden Objekte

 $n! = \text{Fakult\"{a}t} \text{ von } n$

(n-k)! = Fakultät von (n-k)

k! = Fakultät von k

Systematik -

Grundbegriffe

Variation (mit Reihenfolge)			Kombination (ohne Reihenfolge)		
Mit Wiederholung Ohne Wiederholung		Mit Wiederholung	Ohne Wiederholung		
n	k	$\frac{n!}{(n-k)!}$	$\binom{n+k-1}{k}$	$\binom{n}{k}$	
Zahlens	schloss	Schwimmwettkampf	Zahnarzt	Lotto	

Variation mit Wiederholung (Zahlenschloss)

Wie viele Möglichkeiten gibt es bei einem Zahlenschloss (0-9) mit 6 Zahlenkränzen?

$$n = 10, \quad k = 6$$
$$n^k = 10^6$$

Variation ohne Wiederholung (Schimmwettkampf)

Bei einem Schwimmwettkampf starten 10 Teilnehmer. Wie viele mögliche Platzierungen der ersten drei Plätze (Podest) gibt es?

$$n = 10, \quad k = 3$$

$$\frac{n!}{(n-k)!} = \frac{10!}{(10-3)!} = \frac{10!}{7!}$$

Kombination mit Wiederholung (Zahnarzt)

3 Spielzeuge werden aus 5 Töpfen gezogen. Jeder Topf ist mit einer (unterschiedlichen) Art von Spielzeug befüllt.

Wie viele Möglichkeiten hat das Kind?

$$n = 5, \quad k = 3$$

$$\binom{n+k-1}{k} = \binom{5+3-1}{3} = \binom{7}{3}$$

Kombination ohne Wiederholung (Lotto)

Wie gross sind die Chancen beim Lotto 6 aus 49 Zahlen richtig zu ziehen? Jede Zahl ist nur einmal vorhanden und die Zahlen werden nicht zurückgelegt. Die Reihenfolge in der gezogen wird spielt keine Rolle.

$$n = 49, \quad k = \binom{n}{k} = \binom{49}{6}$$

Wahrscheinlichkeitsrechnung

Ideen

- Berechnung durch Aufteilung in mehrere Kombinationen
- Berechnung über Inverse
- Prozente = Wahrscheinlichkeit / Gesamt-Wahrscheinlichkeit

Wahrscheinlichkeit bei Rommé

Beim Rommé spielt man mit 110 Karten: sechs davon sind Joker. Zu Beginn eines Spiels erhält jeder Spieler genau 12 Karten.

In wieviel Prozent aller möglichen Fälle sind darunter genau zwei Joker?

$$\frac{\binom{6}{2} \cdot \binom{104}{10}}{\binom{110}{12}}$$

In wieviel Prozent aller möglichen Fälle ist darunter **mindestens ein** Joker?

$$1 - \frac{\binom{104}{12}}{\binom{110}{12}}$$

Geschwister und Geburtsmonat

Sind in mehr als 60% aller Fälle von vier (nicht gleichaltrigen) Geschwistern mindestens zwei im gleichen Monat geboren?

$$1 - \frac{12 \cdot 11 \cdot 10 \cdot 9}{12^4}$$

Anordnung von Büchern

Auf wie viele Arten lassen sich 10 Bücher in ein Regal reihen?

$$n = 10, \quad k = 10$$

$$\frac{n!}{(n-k)!} = 10!$$

Glühbirnen auswählen

Von 100 Glühbirnen sind genau drei defekt. Es werden nun 6 Glühbirnen zufällig ausgewählt.

Wie viele Möglichkeiten gibt es, wenn sich **mindestens eine defekte** Glühbirne in der Auswahl befinden soll?

$$\binom{100}{6} - \binom{97}{6} = 203'880'032$$

Mit wie viel Prozent Chancen ist bei einer Auswahl von 6 Glühbirnen keine defekt?

 $\frac{\binom{97}{6}}{\binom{100}{6}}$

Buchstabenkombinationen

Wie viele Worte lassen sich aus den Buchstaben des Wortes ABRA-KADABRA bilden? (Nur Worte in denen alle Buchstaben vorkommen!) A=5x, B=2x, R=2x, D=1x, K=1x

$$\binom{11}{5} \cdot \binom{6}{2} \cdot \binom{4}{2} \cdot \binom{2}{1} \cdot \binom{1}{1} = 83160$$

Wahrscheinlichkeitstheorie

Ergebnisraum

Ergebnisraum Ω ist die Menge aller möglichen Ergebnisse des Zufallsexperiments. Zähldichte $\rho:\Omega\to[0,1]$ ordnet jedem Ereignis seine Wahrscheinlichkeit zu.

Für ein Laplace-Raum (Ω, P) gilt:

$$P(M) = \frac{|M|}{|\Omega|}$$

 $\Omega = \text{Ergebnisraum}$ (Menge aller möglichen Ergebnisse)

P(M) = Wahrscheinlichkeit des Ereignisses M

|M| = Anzahl der für M günstigen Ergebnisse

 $|\Omega|$ = Anzahl aller möglichen Ergebnisse

Stochastische Unabhängigkeit

Zwei Ereignisse A und B heissen stochastisch unabhängig, falls:

$$P(A \cap B) = P(A) \cdot P(B)$$

 $P(A \cap B)$ = Wahrscheinlichkeit dass beide Ereignisse eintreten

P(A) = Wahrscheinlichkeit von Ereignis A

P(B) = Wahrscheinlichkeit von Ereignis B

Zwei Zufallsvariablen $X:\Omega\to\mathbb{R}$ und $Y:\Omega\to\mathbb{R}$ heissen stochastisch unabhängig, falls:

$$P(X=x,Y=y)=P(X=x)\cdot P(Y=y),\quad \text{für alle } x,y\in\mathbb{R}$$

P(X = x, Y = y) = Wahrscheinlichkeit dass X den Wert x und Y den Wert y annimmt

P(X = x) = Wahrscheinlichkeit dass X den Wert x annimmt P(Y = y) = Wahrscheinlichkeit dass Y den Wert y annimmt

Bedingte Wahrscheinlichkeit -

Bedingte Wahrscheinlichkeit

$$P(B \mid A) = \frac{P(B \cap A)}{P(A)}$$

P(B|A)= Wahrscheinlichkeit von Bunter der Bedingung dass Aeingetreten ist

 $P(B\cap A)=$ Wahrscheinlichkeit dass beide Ereignisse eintreten P(A)= Wahrscheinlichkeit von EreignisA

Multiplikationssatz

$$P(A \cap B) = P(A) \cdot P(B \mid A) = P(B) \cdot P(A \mid B)$$

 $P(A \cap B) = \text{Wahrscheinlichkeit dass beide Ereignisse eintreten}$

P(A) = Wahrscheinlichkeit von Ereignis A

 $P(B|A)=\mbox{Wahrscheinlichkeit}$ von Bunter der Bedingung dass Aeingetreten ist

P(A|B) = Wahrscheinlichkeit von Aunter der Bedingung dass Beingetreten ist

Kenngrössen (Varianz und Erwartungswert)

$$E(X + Y) = E(X) + E(Y), \quad E(\alpha X) = \alpha E(X)$$

$$V(X) = E(X^2) - E(X)^2 = \left[\sum_{x \in \mathbb{R}} P(X = x) \cdot x^2\right] - E(X)^2$$

 $V(\alpha X + \beta) = \alpha^2 \cdot V(X), \quad S(X) = \sqrt{V(X)}$

E(X) = Erwartungswert der Zufallsvariable X

V(X) = Varianz der Zufallsvariable X

S(X) = Standardabweichung der Zufallsvariable X

 $\alpha, \beta = \text{Konstanten}$

P(X = x) = Wahrscheinlichkeit, dass X den Wert x annimmt

 $\sum_{x \in \mathbb{R}}$ = Summe über alle möglichen Werte von x in den reellen Zahlen

Verteilungen und Erwartungswerte

Für diskrete Verteilungen:

$$E(X) = \sum_{x \in \mathbb{R}} f(x) \cdot x$$
$$V(X) = \sum_{x \in \mathbb{R}} f(x) \cdot (x - E(X))^2$$

E(X) = Erwartungswert der Zufallsvariable X

V(X) = Varianz der Zufallsvariable X

f(x) = Wahrscheinlichkeitsfunktion

x = Mögliche Werte der Zufallsvariable

Für stetige Verteilungen:

$$E(X) = \int_{-\infty}^{\infty} f(x) \cdot x dx$$
$$V(X) = \int_{-\infty}^{\infty} f(x) \cdot (x - E(X))^{2} dx$$

E(X) = Erwartungswert der Zufallsvariable X

V(X) = Varianz der Zufallsvariable X

f(x) = Dichtefunktion

x = Mögliche Werte der Zufallsvariable

Satz von der Totalen Wahrscheinlichkeit

$$P(B) = P(A) \cdot P(B \mid A) + P(\bar{A}) \cdot P(B \mid \bar{A})$$

P(B) = Wahrscheinlichkeit von Ereignis B

P(A) = Wahrscheinlichkeit von Ereignis A

 $P(\bar{A}) = \text{Wahrscheinlichkeit des Gegenereignisses von } A$

 $P(B|A)=\mbox{Wahrscheinlichkeit}$ von Bunter der Bedingung dass Aeingetreten ist

 $P(B|\bar{A})=$ Wahrscheinlichkeit von Bunter der Bedingung dass Anicht eingetreten ist

Satz von Bayes

$$P(A \mid B) = \frac{P(A) \cdot P(B \mid A)}{P(B)}$$

P(A|B) = Wahrscheinlichkeit von A unter der Bedingung dass B eingetreten ist

P(A) = Wahrscheinlichkeit von Ereignis A

P(B|A)= Wahrscheinlichkeit von Bunter der Bedingung dass Aeingetreten ist

P(B) = Wahrscheinlichkeit von Ereignis B

Spezielle Verteilungen

Verteilungen und Erwartungswerte Für diskrete Verteilungen:

$$E(X) = \sum_{x \in \mathbb{R}} f(x) \cdot x$$

$$K(X) = \sum_{x \in \mathbb{R}} f(x) \cdot (x - E(X))$$

 $V(X) = \sum_{x \in \mathbb{R}} f(x) \cdot (x - E(X))^2$

E(X) = Erwartungswert der Zufallsvariable X

V(X) = Varianz der Zufallsvariable X

f(x) = Wahrscheinlichkeitsfunktion

x = Mögliche Werte der Zufallsvariable

Für stetige Verteilungen:

$$E(X) = \int_{-\infty}^{\infty} f(x) \cdot x dx$$
$$V(X) = \int_{-\infty}^{\infty} f(x) \cdot (x - E(X))^{2} dx$$

E(X) = Erwartungswert der Zufallsvariable X

V(X) = Varianz der Zufallsvariable X

f(x) = Dichtefunktion

x = Mögliche Werte der Zufallsvariable

Bernoulliverteilung Bernoulli-Experimente sind Zufallsexperimente mit nur zwei möglichen Ergebnissen (1 und 0):

$$P(X = 1) = p$$
, $P(X = 0) = 1 - p = q$

Es gilt:

1. $E(X) = E(X^2) = p$

2.
$$V(X) = p \cdot (1-p)$$

E(X) = Erwartungswert

V(X) = Varianz

P(X = 1) = Wahrscheinlichkeit für Erfolg

p = Erfolgswahrscheinlichkeit

q = Gegenwahrscheinlichkeit (1 - p)

Normalverteilung -----

Gauss-Verteilung Die stetige Zufallsvariable X folgt der Normalverteilung mit den Parametern $\mu, \sigma \in \mathbb{R}, \sigma > 0$:

$$\varphi_{\mu,\sigma}(x) = \frac{1}{\sqrt{2\pi} \cdot \sigma} \cdot e^{-\frac{1}{2}(\frac{x-\mu}{\sigma})^2}$$

Standardnormalverteilung ($\mu = 0$ und $\sigma = 1$):

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{1}{2}x^2}$$

 $\varphi_{\mu,\sigma}(x)$ = Dichtefunktion der Normalverteilung $\varphi(x)$ = Dichtefunktion der Standardnormalverteilung

 $\mu = \text{Erwartungswert}$

 $\sigma = \text{Standardabweichung}$

e = Eulersche Zahl

 $\pi = \text{Kreiszahl Pi}$

Die Verteilungsfunktion der Normalverteilung

Die kumulative Verteilungsfunktion (CDF) von $\varphi_{\mu,\sigma}(x)$ wird mit $\phi_{\mu,\sigma}(x)$ bezeichnet. Sie ist definiert durch:

$$\phi_{\mu,\sigma}(x) = P(X \le x) = \int_{-\infty}^{x} \varphi_{\mu,\sigma}(t) dt = \frac{1}{\sqrt{2\pi} \cdot \sigma} \cdot \int_{-\infty}^{x} e^{-\frac{1}{2} \left(\frac{t-\mu}{\sigma}\right)^2} dt$$

 $\phi_{\mu,\sigma}(x)$ = Verteilungsfunktion der Normalverteilung

 $\varphi_{\mu,\sigma}(x) = \text{Dichtefunktion der Normalverteilung}$

 $P(X \le x) = \text{Wahrscheinlichkeit dass } X \text{ kleiner oder gleich } x \text{ ist}$

 $\mu = \text{Erwartungswert}$

 $\sigma = \text{Standardabweichung}$

 $\pi = \text{Kreiszahl Pi}$

e = Eulersche Zahl

Approximation durch die Normalverteilung

• Binomial verteilung: $\mu = np, \sigma^2 = npq$

• Poissonverteilung: $\mu = \lambda, \sigma^2 = \lambda$

$$P(a \le X \le b) = \sum_{x=a}^{b} P(X = x) \approx \phi_{\mu,\sigma}(b + \frac{1}{2}) - \phi_{\mu,\sigma}(a - \frac{1}{2})$$

 $P(a \le X \le b)$ = Wahrscheinlichkeit dass X zwischen a und b liegt $\phi_{\mu,\sigma}$ = Verteilungsfunktion der Normalverteilung a,b = Untere und obere Grenze

Standardisierung der Normalverteilung

Bei einer stetigen Zufallsvariable X lässt sich die Verteilungsfunktion als Integral einer Funktion f darstellen:

$$F(x) = P(X \le x) = \int_{-\infty}^{x} f(u) \cdot du$$

Liegt eine beliebige Normalverteilung $N(\mu,\sigma)$ vor, muss standardisiert werden. Statt ursprünglichen Zufallsvariablen X betrachtet man die Zufallsvariable:

$$U = \frac{X - \mu}{\sigma}$$

F(x) = Verteilungsfunktion

 $P(X \leq x) = \text{Wahrscheinlichkeit dass } X \text{ kleiner oder gleich } x \text{ ist}$

f(u) = Dichtefunktion

U = Standardisierte Zufallsvariable

X = Ursprüngliche Zufallsvariable

 $\mu = \text{Erwartungswert}$

 $\sigma = \text{Standardabweichung}$

Erwartungswert und Varianz der Normalverteilung

Für eine Zufallsvariable $X \sim N(\mu; \sigma)$ gilt:

$$E(X) = \mu, \quad V(X) = \sigma^2$$

E(X) = Erwartungswert der Zufallsvariable X

V(X) = Varianz der Zufallsvariable X

 $\mu = \text{Erwartungsparameter}$

 $\sigma^2 = \text{Varianzparameter}$

Zentraler Grenzwertsatz

Für eine Folge von Zufallsvariablen X_1, X_2, \ldots, X_n mit gleichem Erwartungswert μ und gleicher Varianz σ^2 gilt:

$$E(S_n) = n \cdot \mu$$
, $V(S_n) = n \cdot \sigma^2$, $E(\bar{X}_n) = \mu$, $V(\bar{X}_n) = \frac{\sigma^2}{n} = \frac{1}{n^2} \cdot V(S_n)$

 $S_n = \text{Summe der Zufallsvariablen}$

 \bar{X}_n = Arithmetisches Mittel der Zufallsvariablen

n = Anzahl der Zufallsvariablen

 $\mu = \text{Erwartungswert der einzelnen Zufallsvariablen}$

 σ^2 = Varianz der einzelnen Zufallsvariablen

Die standardisierte Zufallsvariable:

$$U_n = \frac{((X_1 + X_2 + \dots + X_n) - n\mu)}{\sqrt{n} \cdot \sigma} = \frac{(\bar{X} - \mu)}{\frac{\sigma}{\sqrt{n}}}$$

Sind die Zufallsvariablen alle identisch $N(\mu, \sigma)$ verteilt, so sind die Summe S_n und das arithmetische Mittel \bar{X}_n wieder normalverteilt

- $S_n: N(n \cdot \mu, \sqrt{n} \cdot \sigma)$
- $\bar{X}_n: N(\mu, \frac{\sigma}{\sqrt{n}})$

Verteilungsfunktion $F_n(u)$ konvergiert für $n \to \infty$ gegen die Verteilungsfunktion $\phi(u)$ der Standardnormalverteilung:

$$\lim_{n \to \infty} F_n(u) = \phi(u) = \frac{1}{\sqrt{2\pi}} \cdot \int_{-\infty}^u e^{-\frac{1}{2}t^2} dt$$

Faustregeln für Approximationen

- Die Approximation (Binomialverteilung) kann verwendet werden, wenn npq > 9
- Für grosses n(n > 50) und kleines p(p < 0.1) kann die Binomialdurch die Poisson-Verteilung approximiert werden:

$$B(n,p)\approx \mathrm{Poi}(n\cdot p)$$

B(n, p) = Binomial verteilung

 $Poi(\lambda) = Poissonverteilung mit Parameter \lambda = n \cdot p$

• Eine Hypergeometrische Verteilung kann durch eine Binomialverteilung angenähert werden, wenn $n < \frac{N}{20}$:

$$H(N, M, n) \approx B(n, \frac{M}{N})$$

H(N, M, n) = Hypergeometrische Verteilung

B(n, p) = Binomial verteilung

N = Grundgesamtheit

M =Anzahl der Erfolge in der Grundgesamtheit

n = Stichprobengröße

Hypergeometrische Verteilung (Ohne zurücklegen)

- N = Objekte gesamthaft
- M = Objekte einer bestimmten Sorte
- n = Stichprobengrösse
- x = Merkmalsträger

$$P(X = x) = \frac{\binom{M}{x} \cdot \binom{N-M}{n-x}}{\binom{N}{n}}$$

Schreibweise: $X \sim H(N, M, n)$

1.
$$\mu = E(X) = n \cdot \frac{\dot{M}}{N}$$
 2. $\sigma^2 = V(X) = n \cdot \frac{M}{N} \cdot (1 - \frac{M}{N}) \cdot \frac{N - n}{N - 1}$ 3. $\sigma = S(X) = \sqrt{V(X)}$

Binomialverteilung (Mit zurücklegen)

- n = Anzahl Wiederholungen
- p = Wahrscheinlichkeit für ein Ergebnis 1

$$P(X = x) = \binom{n}{x} \cdot p^x \cdot q^{n-x}$$

Schreibweise: $X \sim B(n; p)$

1.
$$\mu = E(X) = np$$
 2. $\sigma^2 = V(X) = npq$ 3. $\sigma = S(X) = \sqrt{npq}$

Poisson Verteilung

• $\lambda = \text{Rate}$

$$P(X = x) = \frac{\lambda^x}{r!} \cdot e^{-\lambda}, \quad \lambda > 0$$

Schreibweise: $X \sim Poi(\lambda)$

1.
$$\mu = E(X) = \lambda$$
 2. $\sigma^2 = V(X) = \lambda$ 3. $\sigma = S(X) = \sqrt{\lambda}$

Methode der kleinsten Quadrate

Lineare Regression

Gegeben sind Datenpunkte $(x_i; y_i)$ mit $1 \le i \le n$. Die Residuen / Fehler $\epsilon_i = q(x_i) - y_i$ dieser Datenpunkte sind Abstände in y-Richtung zwischen y_i und der Geraden q. Die Ausgleichs- oder Regressiongerade ist diejenige Gerade, für die die Summe der quadrierten Residuen $\sum_{i=1}^{n} \epsilon_i^2$ am kleinsten ist.

 $(x_i, y_i) = Datenpunkte$

 $\epsilon_i = \text{Residuum}$ (Abweichung) des i-ten Datenpunkts

 $q(x_i) = \text{Wert der Regressionsgerade an der Stelle } x_i$

n = Anzahl der Datenpunkte

Regressionsgerade

Die Regressionsgerade g(x) = mx + d mit den Parametern m und dist die Gerade, für welche die Residualvarianz s_{ϵ}^2 minimal ist.

Steigung:
$$m=\frac{s_{xy}}{s_x^2}, \quad \text{y-Achsenabschnitt: } d=\bar{y}-m\bar{x}, \quad s_\epsilon^2=s_y^2-\frac{s_{xy}^2}{s_x^2}$$

m =Steigung der Regressionsgerade

d = v-Achsenabschnitt

 $s_{xy} = \text{Kovarianz von } x \text{ und } y$

 $s_x^2 = \text{Varianz der } x\text{-Werte}$

 $s_y^2 = \text{Varianz der } y\text{-Werte}$

 $\bar{x} = \text{Arithmetisches Mittel der } x\text{-Werte}$

 $\bar{y} = \text{Arithmetisches Mittel der } y\text{-Werte}$

 $s_{\epsilon}^2 = \text{Residual varianz}$

Bestimmtheitsmass

Varianzaufspaltung

Die Totale Varianz setzt sich zusammen aus der Residualvarianz und der Varianz der prognostizierten Werte:

- s_u^2 Totale Varianz
- s_{ij}^2 prognostizierte (erklärte) Varianz
- s_{ϵ}^2 Residualvarianz

$$s_y^2 = s_\epsilon^2 + s_{\hat{y}}^2$$

 $s_y^2={\it Totale}$ Varianz der beobachteten $y{\it -}{\it Werte}$

 $s_{\epsilon}^{2}=$ Varianz der Residuen $s_{\hat{u}}^{2}=$ Varianz der durch die Regression geschätzten Werte

Bestimmtheitsmass

Das Bestimmtheitsmass R^2 beurteilt die globale Anpassungsgüte einer Regression über den Anteil der prognostizierten Varianz s_{α}^2 an der totalen Varianz s_n^2 :

$$R^2 = \frac{s_{\hat{y}}^2}{s_y^2}$$

 $R^2 = \text{Bestimmtheitsmass}$ (zwischen 0 und 1)

 $s_{\hat{y}}^2 = \text{Varianz der prognostizierten Werte}$

 $s_u^2 = \text{Totale Varianz}$

Das Bestimmtheitsmass R^2 entspricht dem Quadrat des Korrelationskoeffizienten:

$$R^2 = \frac{s_{xy}^2}{s_x^2 \cdot s_y^2} = (r_{xy})^2$$

 $s_{xy} = \text{Kovarianz von } x \text{ und } y$

 $s_x^2 = \text{Varianz der } x\text{-Werte}$ $s_y^2 = \text{Varianz der } y\text{-Werte}$

 $r_{xy} = \text{Korrelationskoeffizient}$

Linearisierungsfunktionen -

Transformationen

Ausgangsfunktion	Transformation		
$y = q \cdot x^m$	$\log(y) = \log(q) + m \cdot \log(x)$		
$y = q \cdot m^x$	$\log(y) = \log(q) + \log(m) \cdot x$		
$y = q \cdot e^{m \cdot x}$	$\ln(y) = \ln(q) + m \cdot x$		
$y = \frac{1}{q + m \cdot x}$	$V = q + m \cdot x; V = \frac{1}{y}$		
$y = q + m \cdot \ln(x)$	$y = q + m \cdot U; u = \ln(x)$		
$y = \frac{1}{q \cdot m^x}$	$\log(\frac{1}{y}) = \log(q) + \log(m) \cdot x$		

y = Abhängige Variable

x = Unabhängige Variable

q, m = Parameter der Funktion

e = Eulersche Zahl

ln = Natürlicher Logarithmus

log = Logarithmus zur Basis 10

Methode der kleinsten Quadrate -

Matrix-Darstellung

Die Parameter m und q der Regressionsgeraden werden mit der Matrix A berechnet:

$$A = \begin{pmatrix} x_1 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{pmatrix}, \quad A^T \cdot A \cdot \begin{pmatrix} m \\ q \end{pmatrix} = A^T \cdot \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$

Residuenberechnung

Die Residuen ϵ_i ergeben sich als:

$$\epsilon_i = y_i - \hat{y}_i = y_i - (mx_i + q)$$

Die Summe der quadrierten Residuen wird minimiert:

$$\sum_{i=1}^{n} \epsilon_{i}^{2} = \sum_{i=1}^{n} (y_{i} - (mx_{i} + q))^{2} \to \min$$

Schliessende Statistik

Erwartungstreue Schätzfunktion

Eine Schätzfunktion Θ eines Parameters θ heisst erwartungstreu, wenn:

$$E(\Theta) = \theta$$

Effizienz einer Schätzfunktion

Gegeben sind zwei erwartungstreue Schätzfunktionen Θ_1 und Θ_2 desselben Parameters θ . Man nennt Θ_1 effizienter als Θ_2 , falls:

$$V(\Theta_1) < V(\Theta_2)$$

Konsistenz einer Schätzfunktion

Eine Schätzfunktion Θ heisst konsistent, wenn:

$$E(\Theta) \to \theta$$
 und $V(\Theta) \to 0$ für $n \to \infty$

Erwartungstreue Schätzfunktion

Grundgesamtheit mit Erwartungswert μ , Varianz σ^2 und Zufallsstichprobe X_1, X_2, X_3 . Die folgende Schätzfunktion ist gegeben:

$$\Theta_1 = \frac{1}{3} \cdot (2X_1 + X_2)$$

 $\Theta_1 = Schätzfunktion$

 $X_1, X_2 = \text{Zufalls variable n}$ aus der Stichprobe

Ist diese Schätzfunktion erwartungstreu (Parameter: μ)?

$$E(\Theta_1) = E(\frac{1}{3} \cdot (2X_1 + X_2)) = \frac{1}{3} \cdot (2E(X_1) + E(X_2))$$
$$E(\Theta_1) = \frac{1}{3} \cdot (2\mu + \mu) = \frac{3\mu}{3} = \mu$$

 $E(\Theta_1) = \text{Erwartungswert der Schätzfunktion}$

 $E(X_1), E(X_2) = \text{Erwartungswerte der einzelnen Zufallsvariablen}$ $\mu = \text{Wahrer Parameterwert}$

Da $E(\Theta_1) = \mu$ ist die Funktion erwartungstreu.

Effizienz einer Schätzfunktion

Grundgesamtheit mit Erwartungswert μ . Varianz σ^2 und Zufallsstichprobe X_1, X_2, X_3 . Gegeben ist die Schätzfunktion:

$$\Theta_1 = \frac{1}{3} \cdot (2X_1 + X_2)$$

Berechnung der Effizienz:

$$\begin{split} V(\Theta_1) &= V(\frac{1}{3} \cdot (2X_1 + X_2)) \\ &= \frac{1}{9} \cdot V(2X_1 + X_2) \\ &= \frac{1}{9} \cdot (V(2X_1) + V(X_2)) \\ &= \frac{1}{9} \cdot (4V(X_1) + V(X_2)) \\ &= \frac{1}{9} \cdot (4\sigma^2 + \sigma^2) \\ &= \frac{5\sigma^2}{9} \end{split}$$

 $V(\Theta_1) = \text{Varianz der Schätzfunktion}$

 $V(X_1), V(X_2) = \text{Varianzen der einzelnen Zufallsvariablen}$

 σ^2 = Varianz der Grundgesamtheit

Die Effizienz der Schätzfunktion ist also $\frac{5\sigma^2}{\Omega}$.

Vertrauensintervalle ---

Vertrauensintervall

Wir legen eine grosse Wahrscheinlichkeit γ fest (z.B. $\gamma = 95\%$). γ heisst statistische Sicherheit oder Vertrauensniveau. $\alpha = 1 - \gamma$ ist die Irrtumswahrscheinlichkeit.

Dann bestimmen wir zwei Zufallsvariablen Θ_u und Θ_o so, dass sie den wahren Parameterwert Θ mit der Wahrscheinlichkeit γ einschliessen:

$$P(\Theta_u \le \Theta \le \Theta_o) = \gamma$$

Intervallschätzung

Verteilungstypen und zugehörige Quantile:

Verteilung	Parameter	Quantile
Normalverteilung (σ^2 bekannt)	μ	$c = u_p, p = \frac{1+\gamma}{2}$
t-Verteilung (σ^2 unbekannt)	μ	$c = t_{(p;f=n-1)}, p = \frac{1+\gamma}{2}$
Chi-Quadrat-Verteilung	σ^2	$c_1 = \chi^2_{(\frac{1-\gamma}{2};n-1)}, c_2 = \chi^2_{(\frac{1+\gamma}{2};n-1)}$

Berechnung eines Vertrauensintervalls

Geben Sie das Vertrauensintervall für μ an (σ^2 unbekannt). Gegeben

$$n = 10, \quad \bar{x} = 102, \quad s^2 = 16, \quad \gamma = 0.99$$

1. Verteilungstyp mit Param μ und σ^2 unbekannt \to T-Verteilung 2. $f=n-1=9,~p=\frac{1+\gamma}{2}=0.995,~c=t_{(p;f)}=t_{(0.995;9)}=3.25$

3. $e = c \cdot \frac{S}{\sqrt{n}} = 4.111$, $\Theta_u = \bar{X} - e = 97.89$, $\Theta_o = \bar{X} + e = 106.11$

Likelyhood-Funktion ---

Likelyhood-Funktion

Wir betrachten eine Zufallsvariable X und ihre Dichte (PDF) $f_x(x|\theta)$, welche von x und einem oder mehreren Parametern θ ab-

Für eine Stichprobe vom Umfang n mit x_1, \ldots, x_n nennen wir die vom Parameter θ abhängige Funktion die Likelyhood-Funktion der Stichprobe:

$$L(\theta) = f_x(x_1|\theta) \cdot f_x(x_2|\theta) \cdot \ldots \cdot f_x(x_n|\theta)$$

Vorgehen bei Maximum-Likelihood-Schätzung

- 1. Likelyhood-Funktion bestimmen
- 2. Maximalstelle der Funktion bestimmen:
 - (Partielle) Ableitung $L'(\theta) = 0$

Erwartungswert und Varianz (Funktion und Wert)

Erwartungswert:

$$\bar{X} = \frac{1}{n} \cdot \sum_{i=1}^{n} X_i, \quad \hat{\mu} = \bar{x} = \frac{1}{n} \cdot \sum_{i=1}^{n} x_i$$

 $\bar{X} = \text{Arithmetischer Mittelwert (Zufallsvariable)}$

 $\hat{\mu} = \bar{x} = \text{Arithmetischer Mittelwert (Stichprobenwert)}$

n = Stichprobenumfang

 $X_i = i$ -te Zufallsvariable

 $x_i = i$ -ter Stichprobenwert

Varianz:

$$S^{2} = \frac{1}{n-1} \cdot \sum_{i=1}^{n} (X_{i} - \bar{X})^{2}, \quad \hat{\sigma}^{2} = s^{2} = \frac{1}{n-1} \cdot \sum_{i=1}^{n} (x_{i} - \bar{x})^{2}$$

 $S^2 = \text{Stichprobenvarianz}$ (Zufallsvariable)

 $\hat{\sigma}^2 = s^2 = \text{Stichprobenvarianz}$ (Stichprobenwert)

 $\bar{X} = \text{Arithmetischer Mittelwert (Zufallsvariable)}$

 $\bar{x} = \text{Arithmetischer Mittelwert (Stichprobenwert)}$

Detaillierte Vertrauensintervalle -

Verteilungstypen und Quantile

Verteilung	Parameter	Standardisierung	Quantile
Normalverteilung	μ	$U = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}}$	$c = u_p, p = \frac{1+\gamma}{2}$
$(\sigma^2 \text{ bekannt})$		5, 7, 10	
t-Verteilung	μ	$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$	$c = t_{(p; f=n-1)}, p = \frac{1+\gamma}{2}$
$(\sigma^2 \text{ unbekannt})$		2, V.	_
Chi-Quadrat	σ^2	$Z = (n-1)\frac{s^2}{\sigma^2}$	$c_1 = \chi^2_{(1-\gamma)}$
			$c_1 = \chi^2_{(\frac{1-\gamma}{2}; n-1)}$ $c_2 = \chi^2_{(\frac{1+\gamma}{2}; n-1)}$
			$C_2 = \chi_{(\frac{1+\gamma}{2}; n-1)}$

Konfidenzintervalle

Für verschiedene Verteilungen ergeben sich folgende Intervallgrenzen:

1. Normalverteilung (σ^2 bekannt):

$$\Theta_u = \bar{X} - c \frac{\sigma}{\sqrt{n}}, \quad \Theta_o = \bar{X} + c \frac{\sigma}{\sqrt{n}}$$

2. t-Verteilung (σ^2 unbekannt):

$$\Theta_u = \bar{X} - c \frac{S}{\sqrt{n}}, \quad \Theta_o = \bar{X} + c \frac{S}{\sqrt{n}}$$

3. Chi-Quadrat-Verteilung:

$$\Theta_u = \frac{(n-1)s^2}{c_2}, \quad \Theta_o = \frac{(n-1)s^2}{c_1}$$

Beispiele

Erwartungstreue Schätzfunktion Grundgesamtheit mit Erwartungswert μ , Varianz σ^2 und Zufallsstichprobe X_1, X_2, X_3 . Die folgende Schätzfunktion ist gegeben:

$$\Theta_1 = \frac{1}{3} \cdot (2X_1 + X_2)$$

 $\Theta_1 = Schätzfunktion$

 $X_1, X_2 = \text{Zufallsvariablen}$ aus der Stichprobe

Ist diese Schätzfunktion erwartungstreu (Parameter: μ)?

$$\begin{split} E(\Theta_1) &= E(\frac{1}{3} \cdot (2X_1 + X_2)) = \frac{1}{3} \cdot (2E(X_1) + E(X_2)) \\ E(\Theta_1) &= \frac{1}{3} \cdot (2\mu + \mu) = \frac{3\mu}{3} = \mu \end{split}$$

 $E(\Theta_1) = \text{Erwartungswert der Schätzfunktion}$ $E(X_1), E(X_2) = \text{Erwartungswerte der einzelnen Zufallsvariablen}$ $\mu = \text{Wahrer Parameterwert}$

Da $E(\Theta_1) = \mu$ ist die Funktion erwartungstreu.

Intervallschätzung für die Varianz Für die Varianz σ^2 einer Normalverteilung mit Stichprobenumfang n = 10 und Stichprobenvarianz $s^2 = 16$ soll ein 99%-Vertrauensintervall berechnet werden.

1. Verteilungstyp: Chi-Quadrat-Verteilung

2. Freiheitsgrade: f=n-1=93. Quantile: $c_1=\chi^2_{(0.005;9)}=1.735,\ c_2=\chi^2_{(0.995;9)}=23.589$

4. Vertrauensintervall:

$$\frac{(n-1)s^2}{c_2} \le \sigma^2 \le \frac{(n-1)s^2}{c_1}$$

n = Stichprobenumfang

 $s^2 = \text{Stichprobenvarianz}$

 $c_1, c_2 = \text{Chi-Quadrat-Quantile}$ $\sigma^2 = \text{Wahre Varianz der Grundgesamtheit}$

$$\frac{9 \cdot 16}{23.589} \le \sigma^2 \le \frac{9 \cdot 16}{1.735}$$
$$6.10 \le \sigma^2 \le 82.99$$

Bernoulli-Anteilsschätzung Ein Vertrauensintervall für den Parameter peiner Bernoulli-Verteilung soll aus einer Stichprobe mit n = 100 und $\bar{x} = 0.42$ bei einem Vertrauensniveau von 95% berechnet werden.

1. Prüfen der Voraussetzung: $n\hat{p}(1-\hat{p}) = 100 \cdot 0.42 \cdot 0.58 = 24.36 > 9$

2. Quantil: $c = u_{0.975} = 1.96$

3. Standardfehler: $\sqrt{\frac{\bar{x}(1-\bar{x})}{n}} = \sqrt{\frac{0.42 \cdot 0.58}{100}} = 0.0494$

4. Vertrauensintervall:

$$0.42 \pm 1.96 \cdot 0.0494 = [0.323; 0.517]$$

n = Stichprobenumfang

 $\bar{x} = \text{Stichprobenmittelwert (Anteil der Erfolge)}$

 $\hat{p} = \text{Geschätzter Parameter der Bernoulli-Verteilung}$ $u_{0.975} = 97.5$