


Lineare Regression

Definition

Gegeben sind Datenpunkte $(x_i; y_i)$ mit $1 \leq i \leq n$. Die *Residuen* oder *Fehler* $\epsilon_i = y_i - \underbrace{g(x_i)}_{=\hat{y}_i}$ dieser Datenpunkte sind die Abstände in y -Richtung zwischen den beobachteten Werten y_i und den durch die lineare Regression prognostizierten Werten $\hat{y}_i = g(x_i)$. Die *Ausgleichs-* oder *Regressionsgerade* $g(x) = m \cdot x + d$ (in y -Richtung) ist diejenige Gerade, für die die Summe der quadrierten Residuen $\sum_{i=1}^n \epsilon_i^2$ am kleinsten ist.



Zusammenfassung Regressionsgerade:

Die Regressionsgerade $g(x) = m \cdot x + d$ mit den Parametern m und d ist die Gerade, für die die Residualvarianz \tilde{s}_ϵ^2 minimal ist.

Die Regressionsgerade hat die Steigung $m = \frac{\tilde{s}_{xy}}{\tilde{s}_x^2}$

und den y -Achsenabschnitt $d = \bar{y} - m \cdot \bar{x}$

Für die zugehörige (minimale) Residualvarianz gilt: $\tilde{s}_\epsilon^2 = \tilde{s}_y^2 - \underbrace{\frac{\tilde{s}_{xy}^2}{\tilde{s}_x^2}}_{=\tilde{s}_{\hat{y}}^2}$



mit:

Varianz der x_i -Werte: \tilde{s}_x^2

Varianz. der y_i -Werte (Totale Varianz) : \tilde{s}_y^2

Varianz der \hat{y}_i -Werte (Prognostizierte Varianz): $\tilde{s}_{\hat{y}}^2$

Kovarianz: \tilde{s}_{xy}

arithmetische Mittelwerte \bar{x} und \bar{y}

Hinweis: Die Berechnungen können alternativ auch mit den korrigierten Varianzen s_{ϵ}^2 , s_x^2 , s_y^2 , $s_{\hat{y}}^2$ und der korrigierten Kovarianz s_{xy} erfolgen!

Zusammenfassung Bestimmtheitsmass:

Die Totale Varianz setzt sich zusammen aus der Residualvarianz und der Varianz der prognostizierten Werte (*Varianzzerlegung*):

$$\tilde{s}_y^2 = \tilde{s}_{\epsilon}^2 + \underbrace{\tilde{s}_{\hat{y}}^2}_{\substack{\tilde{s}_{xy}^2 \\ \tilde{s}_x^2}}$$

Das *Bestimmtheitsmass* R^2 beurteilt die globale Anpassungsgüte einer Regression über den Anteil der prognostizierten (erklärten) Varianz $\tilde{s}_{\hat{y}}^2$ an der totalen Varianz \tilde{s}_y^2 :

$$R^2 = \frac{\tilde{s}_{\hat{y}}^2}{\tilde{s}_y^2} \text{ bzw. } R^2 = \frac{s_y^2}{s_y^2}$$

Das *Bestimmtheitsmass* R^2 stimmt überein mit dem Quadrat des *Korrelationskoeffizienten* (nach Bravais-Pearson):

$$R^2 = \frac{\tilde{s}_{xy}^2}{\tilde{s}_x^2 \cdot \tilde{s}_y^2} = r_{xy}^2 \text{ bzw. } R^2 = \frac{s_{xy}^2}{s_x^2 \cdot s_y^2} = r_{xy}^2$$

Bestimmung der Regressionsgerade als Matrizenproblem:

Die Parameter m und d werden mit der Matrix $A = \begin{pmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{pmatrix}$ aus den folgenden Normalengleichungen berechnet:



$$A^T \cdot A \cdot \begin{pmatrix} m \\ q \end{pmatrix} = A^T \cdot \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$

Die Methode der kleinsten Quadrate (KQM)

Das lineare, inhomogene Gleichungssystem mit m Gleichungen und n Unbekannten x_1, \dots, x_n

$$\left. \begin{array}{ccccccccc} a_{11}x_1 & + & a_{12}x_2 & + & \dots & + & a_{1n}x_n & = & y_1 + \epsilon_1 \\ a_{21}x_1 & + & a_{22}x_2 & + & \dots & + & a_{2n}x_n & = & y_2 + \epsilon_2 \\ \vdots & & \vdots & & & & \vdots & & \vdots \\ a_{m1}x_1 & + & a_{m2}x_2 & + & \dots & + & a_{mn}x_n & = & y_m + \epsilon_m \end{array} \right\} \Leftrightarrow \underbrace{\begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix}}_{=A} \cdot \underbrace{\begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}}_{=\vec{x}} = \underbrace{\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}}_{=\vec{y}} + \underbrace{\begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_m \end{pmatrix}}_{=\vec{\epsilon}}$$

hat immer (mind.) eine Lösung mit einem *Residuenvektor* $\vec{\epsilon}$ von minimalem Betrag. Diese Lösungen sind Lösungen der *Normalengleichungen* $A^T \cdot A \cdot \vec{x} = A^T \cdot \vec{y}$.

Hat die Matrix A den Rang n , so ist die symmetrische $n \times n$ Matrix $A^T \cdot A$ invertierbar und die einzige Lösung erhält man aus der Gleichung $\vec{x} = (A^T \cdot A)^{-1} \cdot A^T \vec{y}$.

Für die Lösungen \vec{x} gilt immer:

- $A \cdot \vec{x}$ und der Residuenvektor $\vec{\epsilon} = \vec{y} - A \cdot \vec{x}$ sind orthogonal zueinander.
- Es gilt der Satz von Pythagoras (Quadratsummenzerlegung):

$$|\vec{y}|^2 = |A \cdot \vec{x}|^2 + \underbrace{|\vec{y} - A \cdot \vec{x}|^2}_{=|\vec{\epsilon}|^2}$$

Zuletzt geändert: Montag, 11. Dezember 2023, 15:51





[Datenschutz](#)



[Supportanfrage](#)

[Barrierefreiheitserklärung ZHAW Moodle](#)

[Feedback zur ZHAW Moodle Barrierefreiheit](#)

